Het functionele paradigma is de toekomst.

SJORS SPARREBOOM

Hogeschool Rotterdam 0890040@hr.nl

11 januari 2018

Samenvatting

Met de komst van het internet, big data en de toenemende capaciteit van computers is er vernieuwde interesse in de functionele programmeertalen. Dit rapport onderzoekt samen met de lezer de voor en nadelen bij de stelling "Het functionele paradigma is de toekomst." Dit gebeurt op basis van een literatuuronderzoek naar de relaties en verschillen van de heersende programmeerparadigma's. Het onderzoek beperkt zich tot het imperatieve en functionele paradigma. Om het functionele paradigma en zijn plaats binnen de informatica beter te kunnen begrijpen is er binnen dit onderzoek van een minimale kennisgeving van de heersende programmeerparadigma's uitgegaan. Ook is kennis van programmeren wenselijk, maar het onderzoek kan ook prima zonder deze kennis worden gevolgd.

I. Inleiding

It document is een poging om de gemeenschap te overtuigen van de significantie van functioneel programmeren alsook te informeren wat de voordelen en nadelen zijn van dit paradigma.

Functioneel programmeren dankt zijn naam aan zijn fundamentele werking, namelijk de toepassing van functies op argumenten. Dit beschrijft wat het inhoudt, maar wat is nu eigenlijk een functioneel programma? Een mooie beschrijving van een functioneel programma is die van Hughes [6]: "Een functioneel programma is een functie waar de gegeven input voor dit programma wordt behandeld als argument van een functie, welk vervolgens het resultaat hiervan teruggeeft als output".

Het functioneel programmeren is niet nieuw en bestaat al sinds de jaren 40. De fundamentele werking van deze stijl van programmeren is gebaseerd op het *lambda calculus*[1, 14]. Typerend voor deze stijl is dat functies opgebouwd zijn uit andere functies. Een mooi voorbeeld is de hoofd functie (het programma zelf), deze is opgebouwd uit functies, welke op hun beurt ook weer opgebouwd zijn uit functies; dit heet modulariteit een concept dat wordt behandeld in paragraaf ii. Ook zijn functionele programma's inherent parallel [13, 20] en zijn er geen *assignments*, waardoor variabelen met een waarde niet meer kunnen veranderen (zie paragraaf i).

In de rest van dit document zal er worden gediscussieerd over de voor- en nadelen van deze vorm van programmeren en zal er in paragraaf V af worden gesloten met een conclusie op de stelling "Het functionele paradigma is de toekomst".

II. MIDDENSTUK

In dit middenstuk wordt er eerst korte uitleg gegeven over imperatief programmeren. De geïnformeerde lezer kan ervoor kiezen deze paragraaf over te slaan, maar moet onthouden dat kennis van imperatief programmeren benodigd is in de volgende paragrafen.

Opvolgend zal er worden gekeken naar de voordelen en nadelen van de stelling "Het func-

tioneel programmeren is de toekomst".

i. Imperatief programmeren

De term imperatief programmeren is een letterlijke beschrijving van het gedrag dat deze programma's vertonen, namelijk het sequentieel uitvoeren van een lijst van instructies. Echter is het vanuit deze context niet duidelijk wat een imperatief programma is. Een duidelijke beschrijving van imperatief programmeren wordt gegeven door Chailloux, Manoury en Pagano [2, hfdst. 3] en luidt als volgt:

Imperatief programmeren staat in tegenstelling tot functioneel programmeren dichtbij de machine representatie. Het introduceert een *memory state* die door acties van het programma kunnen worden gemodificeerd. Deze acties worden ook wel *instructies* genoemd en een imperatief programma is dan ook een lijst van deze instructies.

Kort samengevat heeft een imperatief programma net als een assembleer programma een memory state concept, dat het mogelijk maakt de staat van een programma aan te passen. Input-output acties zijn in imperatieve programma's dan ook modificaties van het geheugen.

III. ALGEMENE VOORDELEN FUNCTIONEEL PROGRAMMEREN

Uit het onderzoek van TIOBE [19] en IEEE [7] blijkt dat de imperatieve stijl hedendaags nog steeds de populairste vorm van programmeren is. Wat echter opvalt is dat er enkele functionele talen in deze resultaten (Erlang, Scala, F, Haskell, Clojure) staan, en dit is niet toevallig.

In paragraaf i en paragraaf ii wordt de aanleiding van deze nieuwe interesse in functionele talen onderzocht.

i. Parallel en Gedistribueerd programmeren

Sinds de uitvinding van het internet en *big data* is er buiten de academische wereld nieuwe interesse ontstaan in de functionele talen. Zoals beschreven door Wu e.a. [23] zijn er met komst van big data nieuwe manieren van dataverwerking nodig, aangezien de traditionele manieren niet langer toereikend zijn. Deze nieuwe manieren van dataverwerking baseren zich op twee vormen van computatie die door de goedkopere en verbeterde hardware componenten en de komst van de *multicore processor* een geheel nieuw domein aan mogelijkheden openen; namelijk *parallel* en *gedistrubeerd* computeren [4, 23].

Voordat wordt onderozoht waarom fuctionele talen zo geschikt zijn voor parallel en gedistrubeerd programmeren, zal er eerst gekeken moeten worden waarom de imperatieve stijl van programmeren niet volstaat voor deze vorm van computatie.

In paragraaf i wordt al gesproken over het gebruik van een memory state in deze imperatieve programma's. Het is nu juist het gebruik van deze muteerbare memory state die het parallel en gedistribueerd computeren compliceert. Doordat imperatieve programma's inherent sequentieel zijn, is de volgorde van executie in een parallel of gedistrubeerd programma belangrijk. Wijkt de volgorde van executie echter af, dan kan er een *race conditie* ontstaan.

Race condities zijn één van de grootste oorzaken van bugs in een parallel en gedistrubeerd programma en ontstaan wanneer twee processen allebei tegelijkertijd naar een stukje geheugen willen schrijven [6].

Het voorkomen van race race condities is niet gemakkelijk, zeker omdat in een moderne multi-core CPU, deze CPU'S niet dezelfde througput hebben. In Programming in the Age of Concurrency: Software Transactional Memory vertellen Peyton-Jones en Harris dat in imperatieve programma's een concept genaamd locks (ook wel mutexes genoemd) is geïntroduceerd om deze race condities tegen te gaan. Een werkende oplossing, die echter zelf voor een

nieuw probleem zorgt, namelijk deadlock.

Deadlock is een toestand waar elke proces wacht op een ander proces, wat betekent dat een programma niet verder zal gaan en beland is in een oneindige cyclus. Een programma die lijdt aan een situatie waarin er ongewenst mutaties worden gedaan op data en een hierdoor de werking in

Deze toestand is mogelijk door de muteerbare data van een imperatief programma mogelijk is. Programma's met een dergelijke situatie passen dus buiten hun scope data en hebben een *side-effect*.

Het is dus wenselijk side-effects te voorkomen in een programma, maar hoe is dit mogelijk? Volgens Peyton-Jones en Harris [16, 17] ligt de oplossing in het gebruik van een functionele programmeertaal. Functionele programmeertalen hebben geen van de bovengenoemde problemen. Zo zijn ze inherent parallel en is data in deze programma's niet muteerbaar, omdat er geen assigment declaratie is. Dit elimineert een belangrijke bron van bugs, zoals de deadlock en race conditie en maakt de executie volgorde van deze programma's irrelevant.

ii. Schaalbaar en Modulair

In paragraaf I is al kort aangehaald dat functionele programma's modulair zijn doordat functies opgebouwd zijn uit andere functies, een concept genaamd *currying* [12, hfdst. 5].

Het voordeel van currying is door deze manier van functie applicatie, functies gedeeltelijk kunnen worden toepast [6]. Hierdoor kunnen er nieuwe functies van oude afgeleid worden en maakt een functionele taal erg schaalbaar.

Door deze schaalbaarheid is het gemakkelijker modulair software te schrijven. Deze manier van software maken wordt volgens vele al jaren lang beschouwt als één van de belangrijkste punten in het construeren van herbruikbare en onderhoudbare software [8]. Zo spreken ook Chowdhury en Iqbal [3] hun voorkeur uit over de modulaire aanpak van het ontwerpen van software, omdat er hierdoor toekomstige legacy problemen kunnen worden voorkomen; hierover meer in paragraaf ii.

Modulair programmeren is dus een pre, maar wat is een module nu precies? Lipvača [12, hdfst. 6] beschrijft een module als: "Een module een collectie van gerelateerde functies, types en typeclasses". Wat types en typeclasses zijn is in dit document niet relevant. Wat wel relevant is dat door de modulariteit en schaalbaarheid van functionele programma's veel algoritmes vaak korter zijn dan in een imperatief programma. Een voorbeeld hiervan is direct zichtbaar in de implementatie van quicksort. In listing listing 1 zien we een imperatieve versie van quicksort en in listing listing 2 zien we de functionele tegenhanger.

Listing 1: QuickSort in C

```
void Sort(int input[],int left,int right)
 int L = left;
  int R = right;
 int M = input[(left + right) / 2];
    while(input[L] < M)
    while(M < input[R])
     R--;
    if(L \le R)
      int inputLeft = input[L];
      input[L] = input[R];
      input[R] = inputLeft;
      L++:
      R--;
\} while(L < R);
  if(left < R)
    Sort(input, left, R);
  if(L < right)
    Sort(input, L, right);
void QuickSort(int input[], int length)
  Sort(input, 0, length -1);
```

Listing 2: QuickSort in Haskell

```
quicksort :: Ord a => [a] -> [a]
quicksort [] = []
quicksort (p:xs) =
  (quicksort lesser) ++ [p] ++ (quicksort greater)
  where
  lesser = filter (< p) xs
  greater = filter (>= p) xs
```

Wat uit het bovengenoemde voorbeeld opvalt is dat de functionele versie duidelijker en expressiever is, dan de imperatieve versie. In de imperatieve versie is de bedoeling van het programma niet gelijk duidelijk en moet er sequentieel over het programma worden gelopen om te begrijpen wat de bedoeling ervan is. Bij de functionele tegenhanger van dit algorithme is dit probleem niet aanwezig. Deze onduidelijkheid wordt in dit geval weggenoemen door de aanwezigheid van een type signature *quicksort* :: Ord $a \Rightarrow [a] \rightarrow [a]$, wat ons het volgende vertelt: quicksort is een functie, wat 1 argument neemt van het type een lijst van a's, en als uitkomt ons een lijst van a's terug geeft, met als enige restrictie heeft dat het lid is van de type class Ord. Wat een type class inhoud is echter buiten bereik van dit document. Daarnaast is het programma kleiner, waardoor het automatisch makkelijker leesbaarder wordt.

IV. ALGEMENE NADELEN FUNCTIONEEL PROGRAMMEREN

Dat de functionele stijl van programmeren tegenwoording steeds vaker wordt overwogen, is zichtbaar in paragraaf III. Er zijn echter ook gebieden en problemen die zich niet schikken voor een functionele aanpak van het probleem. In paragraaf i en paragraaf ii wordt er dan ook onderzocht waar deze desinteresse vandaan komt.

Portabiliteit en Beschikaarheid

Beschikbaarheid en portabiliteit van functionele talen op verschillende architecturen en platformen is een grote reden waarom het soms beter is te besluiten tegen het gebruik van deze talen en te kiezen voor een imperatieve tegenhanger. Er zijn dan ook genoeg projecten waarvan de ontwikkelaars liever het project hadden gebouwd in een functionele taal, maar vervolgens toch besloten te kiezen voor C of C++. Eén van deze projecten is de taal voor de PRL database. Volgens Wadler [21] besloten onderzoekers van Lucent om deze taal te bouwen in SML, om ultimatum te kiezen C++, omdat SML niet beschikbaar was op het Amdahl mainframe.

Dezelfde problemen zijn te analyseren voor *embedded systems* [5]. Bij het programmeren van deze systemen moet er rekening worden gehouden dat de architectuur van deze veel kan verschillen van de algemene computer en dat er weinig intern geheugen beschikbaar is [15, 22]. Om toch goede programma's te kunnen schrijven voor deze systemen is het dus noodzakelijk voor de programmeur om direct het geheugen te kunnen controleren.

Functionele programma's alloceren echter in korte tijd veel geheugen. Dit is geen probleem op systemen met genoeg geheugen, maar wordt een probleem in een embedded omgeving. Om ervoor te zorgen dat voldoende geheugen beschikbaar is, worden zogenaamde cells na gebruik vrijgegeven door een *garbage collector* [18]. Deze afhankelijkheid van garbage collectie zorgt ervoor dat er beperkte controle is over het geheugen. Dit gebrek over controle van het geheugen maakt de meeste moderne functionele talen niet geschikt voor embedded systemen, zeker de systemen met weinig geheugen of harde *real-time* beperkingen [10].

ii. Legacy code en Infrastructuur

Er is veel commerciële software in de omloop dat is gedateerd en kan profiteren van de voordelen van functioneel programmeren. Om deze voordelen te benutten moet de huidige infrastructuur van deze systemen worden veranderd, wat in de praktijk een nogal lastig en gevoelig onderwerp blijkt te zijn. In de systemen is namelijk hevig geïnvesteerd en de werking ervan is vaak verworven met de gebruiksdoeleinde [3, 11].

Vervanging is dus lastig, zeker als er nage-

gaan wordt dat na decennia lang schrijven van software, systemen vaak samengesteld zijn uit componenten. Veel van deze componenten zijn geschreven in een imperatieve programmeertaal zoals C of C++. Hierdoor is een *foreign function interface* met C of C++ vaak noodzakelijk zijn om de achterwaartse comptabiliteit te garanderen[21]. Echter door de isolationistische natuur van functionele talen zijn deze foreign function interfaces moeilijk implementeerbaar en word er vaak nog steeds gekozen voor makkelijk koppelbare imperatieve programmeertaal.

V. Conclusie

In dit document is er gediscussieerd over de voordelen en nadelen van het functioneel programmeren. In paragraaf III wordt duidelijk dat met de komst van het internet en de ontwikkelingen op hardware gebied er nieuwe interesse is ontstaan voor functioneel programmeren.

De schaalbaarheid, modulariteit, niet muteerbare datastructuren en het inherent vermogen om parallel expressies te evalueren maakt functioneel programmeren een programmeertsstijl die zeer geschikt is om software te schrijven voor de 21^e eeuw.

Het is echter misschien iets te vroeg om te stellen dat de functionele stijl van programmeren de toekomst is. Zo is er nog steeds geen functionele opmars zichtbaar in de embedded systems hoek en worden legacy problemen in grote commerciële software systemen nog altijd imperatief opgelost.

De toekomst voor de functionele stijl van programmeren is veelbelovend en door de verbeteringen in hardware en de toenemende complexiteit van de programma's zien we dat veel wetenschappers en hedendaags ook steeds meer bedrijven kiezen voor een functionele oplossing van het probleem. Echter zal er goed moet worden gekeken naar het probleem en de context waarin deze zich bevindt, omdat het functionele paradigma niet voor elke situatie kan bijdragen aan een solide oplossing paragraaf ii.

REFERENTIES

- [1] Henk Barendregt. *The Lambda Calculus: Its Syntax and Semantics*. Studies in Logic and the Foundations of Mathematics. Elsevier Science, 2013. ISBN: 978-0-08-093375-7.
- [2] Emmanuel Chailloux, Pascal Manoury en Bruno Pagano. *Developing Applications with Objective Caml*. OREILLY, 2000, p. 1–742. ISBN: 2-84177-121-0.
- [3] Maria Wahid Chowdhury en Muhammad Zafar Iqbal. *Integration of Legacy Systems in Software Architecture*. Tech. rap. University of Victoria, Department of Computer Science e.a.
- [4] Raul Castro Fernandez e.a. *Making State Explicit for Imperative Big Data Processing*. Tech. rap. Imperial College London, University of Kent en City University London.
- [5] Thomas A. Henzinger en Joseph Sifakis. "The Embedded Systems Design Challenge". In: *Proceedings of the 14th International Symposium on Formal Methods (FM), Lecture Notes in Computer Science*. Springer, 2006, p. 1–15.
- [6] John Hughes. Why functional programming matters. Tech. rap. Glasgow University, 1989.
- [7] IEEE. The 2017 top programming languages. 2017. URL: https://spectrum.ieee.org/computing/software/the-2017-top-programming-languages.
- [8] Simon Peyton Jones. "An exploration of modular programs". In: *In The Glasgow Workshop on Functional Programming*. 1996, p. 96.
- [9] Simon Peyton Jones e.a. Harnessing the Multicores: Nested Data Parallelism in Haskell. Tech. rap. University of New South Wales, School of Computer Science, Engineering en Microsoft Research Ltd, 2008.

- [10] Martin Kero en Simon Aittamaa. *Scheduling garbage collection in real-time systems*. Tech. rap. Jan 2010, p. 51–60.
- [11] B. P. Lientz, E. B. Swanson en G. E. Tompkins. "Characteristics of Application Software Maintenance". In: *Commun. ACM* 21.6 (jun 1978), p. 466–471. ISSN: 0001-0782.
- [12] Miran Lipvača. *Learn You a Haskell for Great Good!* 1ste ed. No Starch Press, apr 2011, p. 400. ISBN: 1-59327-283-9.
- [13] Björn Lisper. Functional Programming and Parallel Computing. Tech. rap. Mälardalen University, School of Innovation, Design en Engineering, 2013.
- [14] Greg Michaelson. *An Introduction to Functional Programming Through Lambda Calculus*. Dover books on mathematics. Dover Publications, 2011. ISBN: 978-0-486-47883-8
- [15] Gergely Patai. Functional Programming and Embedded Systems. Tech. rap. Budapest University of Technology, Economics, Faculy of Electrical Engineering en Informatics, 2006.
- [16] The Future is Parallel, and the Future of Parallel is Declarative. 2012.
- [17] Simon Peyton-Jones en Tim Harris. Programming in the Age of Concurrency: Software Transactional Memory. 2017. URL: https://channel9.msdn.com/shows/Going + Deep / Programming in the Age of Concurrency Software Transactional-Memory/.
- [18] Patrick M. Sansom en Simon L. Peyton Jones. "Generational garbage collection for Haskell". In: In Functional Programming Languages and Computer Architecture. ACM Press, 1993, p. 106–116.
- [19] TIOBE. TIOBE Index for January 2018. Jan 2018. URL: http://www.tiobe.com/tiobe-index.

- [20] G. Tremblay en G. R. Gao. "The Impact of Laziness on Parallelism and the Limits of Strictness Analysis". In: PROCEEDINGS HIGH PERFORMANCE FUNCTIONAL COMPUTING. 1995, p. 119–133.
- [21] Philip Wadler. "Why No One Uses Functional Languages". In: *SIGPLAN Not.* 33.8 (aug 1998), p. 23–27. ISSN: 0362-1340.
- [22] Malcolm Wallace. "Functional Programming and Embedded Systems". Proefschrift. University of York, 1995.
- [23] Xindong Wu e.a. *Data Mining with Big Data*. Tech. rap. Hefei University of Technology, School of Computer Science en Information Engineering.

A. TERMINOLOGIE

Assignment:

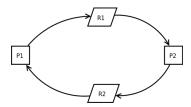
Een assignment stelt de waarde in die is opgeslagen in de opslaglocatie dat wordt aangeduid met een variabelenaam.

Big Data:

Data sets die zo enorm en complex zijn dat traditionele dataverwerkingssoftware niet langer toereikend zijn.

Deadlock:

Deadlock, zoals te zien in fig. 1 is een toestand waarin elk proces wacht op een ander proces. Deze toestand kan voorkomen wanneer de locks worden verkregen in de verkeerde volgorde.




Figuur 1: *Deadlock (source: wikipedia.org/wiki/Deadlock)*

Foreign function interface:

Een *foreign function interface* (FFI) is een mechanisme waarmee een programma dat in een programmeertaal is geschreven, routines kan noemen of gebruik kan maken van services die in een andere taal zijn geschreven.

Gedistribueerde computatie:


Een *gedistribueerd computatie* is een computatie waar een enkele taak wordt opgesplitst in meerdere subtaken. Deze subtaken worden vervolgens gedistribueerd over verschillende nodes in een netwerk en onafhankelijk berekent. Als al deze computaties gedaan zijn zullen deze onafhankelijke berekeningen worden samengevoegd tot één resultaat, zoals te zien in fig. 2.



Figuur 2: *Gedistribueerd proces*

Lock/Mutex:

Lock, zoals te zien in fig. 3 is een mechanisme om het benaderen van een bron in een omgeving te beperken.



Figuur 3: *Lock/Mutex*


Memory leak:

Een *Memory leak* betekent dat een programma meer geheugen toewijst dan nodig voor de executie. Dit kan over tijd erg oplopen aangezien dit niet gebruikte geheugen nooit opnieuw toegewezen kan worden, zonder het wordt gedealloceerd.

Multi-core processor:

Multi-core processoren, bestaan uit verschillende processoren en gedeeld geheugen, zie fig. 4. Deze processoren zijn sneller en hebben een lager energieverbruik dan de single-core processor, zie fig. 7, echter is het programmeren voor deze architectuur een stuk lastiger.

Memory state:



Figuur 4: Multi-core processor


Memory state alle opgeslagen ingegeven waardes van een programma als variabelen of constanten. Bij het analyseren van de status van dit programma kunnen programmeurs deze opgeslagen ingegeven waardes bekijken.

Parallelle computatie:

Een *parallelle computatie* is een vorm van computatie waarin meerdere calculaties simultaan kunnen worden uitgevoerd. Deze vorm van executie is sinds de komst van de multi-core processor, zie fig. 4 het dominante paradigma in computer architectuur.

Een parallelle executie van een proces wordt gedaan door gebruik te maken van threads, zie fig. 6. In fig. 5 is een parallelle executie op een multi-core processor zichtbaar (fig. 4).

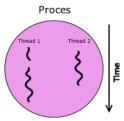
Wat opvalt zijn de extra kernen van deze architectuur, die een single-core processor, zoals te zien in fig. 7 niet heeft. Als deze verschillende kernen zinnig werk tegelijkertijd doen kan dit het gehele proces versnellen.



Figuur 5: Parall proces

Process & Thread:

Een *thread* is de kleinste sequentie van een programma dat onafhankelijk kan opereren. Hoe een proces en thread opereren hangt af van de implementatie van het operatie systeem. De meeste voorkomende implementatie is dat een thread een onderdeel is van het proces, zoals te zien in fig. 6.



Figuur 6: Thread

Race conditie:

Twee processen P1 en P2, kunnen beide schrijven naar de variabel tmp. De intentie van de programmeur is dat zowel proces P1 als P2 tmp van een waarde voorziet, deze vervolgens gelijk te gebruiken en een uiteindelijke waarde voor y en z te presenteren. De executie van algoritme 1 levert de volgende waardes voor y en z:

$$y = 24, z = 2055$$

Echter doordat de processen op verschillende snelheden kunnen draaien, doet zich een situatie voor, zoals te zien in algoritme algoritme 2 waar de volgorde van executie niet wordt uitgevoerd zoals de programmeur had bedoeld. De executie van levert de volgende waardes voor *y* en *z*:

$$y = 4096, z = 2055$$

Zoals te zien is dit niet de juiste waarde voor *y*. Deze situatie wordt ook wel een race conditie genoemd in de informatica.

Algorithm 1 Programmeurs intentie Shared Variable tmp end Shared Variable		Algorithm 2 Race conditie Shared Variable tmp end Shared Variable	
	z = tmp + 7		tmp = 2048
		$y = 2 \times tmp$	
tmp = 12			z = tmp + 7
$y = 2 \times tmp$			
end procedure	end procedure	end procedure	end procedure

Real-time proces:


Een *real-time proces* is een proces waarin een programma het resultaat moet garanderen binnen een bepaalde tijd.

Side-effect:

Binnen de informatica heeft een programma, functie of expressie een *side-effect* wanneer het een waarde buiten zijn scope aanpast of een interactie heeft met zijn aanroep functies of de rest van het programma zonder een waarde te retourneren.

Single-core Processor:

Single-core processoren hebben maar 1 processor direct verbonden aan het geheugen. Deze processoren zijn gemakkelijk te programmeren, maar hebben echter een lagere hoog energieverbruik en een lage prestatie, in tegenstelling tot de multi-core processor, zie fig. 4.



Figur 7: Single-core processor

Throughput:

Throughput is de maximale snelheid waarop iets kan worden verwerkt.